

Fine-tuning Whisper modela za automatsko prepoznavanje govora na srpskom jeziku

Miloš Milanović (R25/2025), Bojan Živanić (R222/2025)

Softversko inženjerstvo i informacione tehnologije, Univerzitet u Novom Sadu, Fakultet tehničkih nauka

milanovic.r25.2025@uns.ac.rs, zivanic.r222.2025@uns.ac.rs

Apstrakt – Automatsko prepoznavanje govora (ASR, eng. *Automatic Speech Recognition*) na srpskom jeziku predstavlja aktivan istraživački problem usled ograničene dostupnosti anotiranih korpusa i specifičnosti fonološkog sistema srpskog jezika. U ovom radu prezentovan je end-to-end ASR sistem zasnovan na *fine-tuningu* openai/whisper-base modela nad skupom audio-tekst parova prikupljenih sa portala Radio-televizije Srbije (RTS). Ključni doprinos je *alignment-first* pristup pripremi podataka koji kombinuje automatsko vremensko poravnanje na nivou reči sa višeslojnom kontrolom kvaliteta segmenata, čime se eksplicitno minimizuje problem pogrešnog nadzornog signala (eng. *garbage supervision*). Implementirana je i striktna *holdout* procedura sa automatizovanom verifikacijom odsustva curenja podataka, bez preklapanja audio izvora između skupova. Evaluacija sprovedena na velikom Kaggle skupu (2.172 segmenta) pokazuje da *fine-tuned* model postiže WER (eng. *Word Error Rate*) od 0,4877 u poređenju sa baseline vrednošću 0,4944, što odgovara apsolutnom smanjenju od 0,0067 i relativnom poboljšanju od 1,36%. Wilcoxon test potvrđuje statističku značajnost poboljšanja ($p = 0,000012$). Analiza grešaka otkriva da lingvističke greške, pre svega konfuzija dijakritičkih znakova srpskog jezika, dominiraju sa 87,25% svih grešaka, dok OOV (eng. *Out-of-Vocabulary*) analiza potvrđuje značajno proširenje aktivnog vokabulara modela. Rezultati naglašavaju da su kvalitet poravnanja podataka i reproduktivna evaluaciona disciplina ključni činioci uspešnog domenski prilagođenog ASR-a u uslovima ograničenih resursa.

Ključne reči – automatsko prepoznavanje govora, fine-tuning Whisper, srpski jezik, low-resource ASR, garbage supervision

I. UVOD

Automatsko prepoznavanje govora (ASR) je tehnologija koja pretvara kontinuirani govorni signal u pisani tekst. Uprkos izuzetnom napretku koji su u ovoj oblasti doneli modeli zasnovani na dubokim neuronskim mrežama, srpski jezik i dalje spada u grupu tzv. *low-resource* jezika. Ova karakterizacija podrazumeva ograničenu količinu javno dostupnih anotiranih audio korpusa, nedovoljnu zastupljenost u trening skupovima velikih višezjezičnih modela i malo istraživačkog rada posvećenog specifičnostima srpske fonologije u kontekstu ASR-a [1]. Pored toga, srpski jezik karakteriše bogata fleksiona morfologija, korišćenje dva ravnopravna pisma, ćirilice i latinice, i fonološka distinktivnost dijakritičkih znakova za značenje (č/c, ž/z) koji su česti izvor grešaka u ASR sistemima [2].

Informativni medijski domen dodatno komplikuje problem. Govorni snimci iz ovog domena karakterišu formalni stil, domenski specifičan rečnik (politička, sportska, kulturna terminologija), heterogeni akustički uslovi (studijska snimanja, terenske reportaže, direktni prenosi) i visoka varijabilnost govornika. Kombinacija ovih činalaca zahteva domenski prilagođene modele koji će biti trenirani i evaluirani na reprezentativnom uzorku iz konkretnog domena.

Motivacija za rešavanje ovog problema je višeslojna. Sa aspekta dostupnosti, automatska transkripcija informativnog audio sadržaja otvara mogućnost automatskog titlovanja čime se sadržaj čini dostupnim osobama sa oštećenjem sluha. Sa aspekta pretražljivosti, digitalizovane medijske arhive bez transkripcija praktično su nepretražive. ASR otvara mogućnost semantičke pretrage kroz istorijski arhiv snimaka. Konačno, sa naučnog aspekta, razvoj i evaluacija ASR sistema za srpski jezik u specifičnom domenu doprinosi opštem napretku obrade srpskog prirodnog jezika koji je nedovoljno istražena oblast.

Savremeni pristupi ASR-u sve više se oslanjaju na velike prethodno trenirane modele koji se naknadno prilagođavaju (eng. *fine-tune*) na ciljni domen ili jezik. Whisper [3], razvijen od strane kompanije OpenAI, posebno je pogodan za ovaj pristup zahvaljujući robusnosti na akustički šum i podršci za višezjezičnu transkripciju na više od 90 jezika. Međutim, pri *fine-tuningu* na malim domenskim skupovima ključan ograničavajući faktor ostaje kvalitet trening podataka. Netačno vremensko poravnanje između audio segmenta i referentnog teksta, tzv. *garbage supervision* problem, direktno narušava kvalitet nadzornog signala i ograničava dobitak od *fine-tuninga*, bez obzira na količinu dostupnih podataka.

Konkretni doprinosi ovog rada su četvorostruki:

- Automatizovana akvizicija audio-tekst parova sa RTS portala uz striktnu ulaznu validaciju i evidenciju problematičnih parova.
- *Alignment-first* pristup segmentaciji koji kombinuje vremenske oznake na nivou reči sa višekriterijumskim proverama kvaliteta segmenata.
- Dvostepena podela podataka sa automatizovanom verifikacijom odsustva curenja na nivou izvornih fajlova
- Sveobuhvatna evaluacija zasnovana na WER (eng. *Word Error Rate*) i CER (eng. *Character Error Rate*) metrikama upotpunjena akustičkom

analizom, lingvističkom analizom, taksonomijom grešaka i statističkim testiranjem.

Ostatak rada organizovan je na sledeći način. U poglavlju II dat je pregled relevantnih istraživanja u oblasti ASR-a, sa fokusom na *low-resource* scenario i *fine-tuning* pristupe. Poglavlje III detaljno opisuje primenjenu metodologiju uključujući akviziciju podataka, *alignment-first* pipeline, proceduru podele i trening konfiguraciju. Poglavlje IV prikazuje rezultate i sveobuhvatnu diskusiju, a poglavlje V sadrži zaključne napomene i pravce budućeg rada.

II. PREGLED LITERATURE

Istraživanja ASR-a za srpski jezik ostaju ograničena u poređenju sa resursno bogatijim jezicima. Mozilla Common Voice [1] korpus obuhvata srpski jezik sa nekoliko stotina validiranih sati, što je znatno manje od resursa dostupnih za engleski ili mandarinski. Raniji pristupi srpskom ASR-u oslanjali su se uglavnom na hibridne GMM-HMM (eng. *Gaussian Mixture Model – Hidden Markov Model*) arhitekture, često kombinovane sa *n-gram* jezičkim modelima [2]. Prelaz na end-to-end neuronske pristupe omogućio je značajan napredak, ali je zahtevao i znatno veće količine trening podataka.

Whisper [3] je *encoder-decoder* model treniran na 680.000 sati višezjezičnog audio sadržaja primenom slabog nadzora (eng. *weak supervision*). Model koristi Transformer arhitekturu za oba dela: enkoder obrađuje log-Mel spektrogram audio ulaza, dok dekodek autoregresivno generiše transkripciju. Model demonstrira izvanrednu robusnost na akustički šum i podržava transkripciju na više od 90 jezika, uključujući srpski. Međutim, osnovna verzija modela je trenirana pretežno na audio snimcima sa interneta, što može rezultirati slabijim performansama na specifičnim domenima ili jezičkim registrima koji su nedovoljno zastupljeni u trening skupu.

Istraživanja u oblasti konstruisanja govornih korpusa pokazala su da kvalitet trening podataka ima dominantni uticaj na performanse ASR sistema, posebno u uslovima ograničenih anotiranih resursa za *low-resource* jezike [4]. Ovaj nalaz je posebno relevantan za scenario automatski prikupljenih audio-tekst parova bez ručne anotacije, u kojima greške vremenskog poravnanja između audio segmenta i referentnog teksta mogu biti značajan izvor šuma u nadzornom signalu.

Wav2Vec 2.0 [5] i srodne samo-nadzirane (eng. *self-supervised*) arhitekture pokazale su dobre rezultate u ASR za *low-resource* jezike učenjem reprezentacija govora iz velikih količina neanotiranog audio sadržaja. HuBERT [6] proširio je ovaj pristup iterativnim klasterovanjem. Iako su ovi pristupi razmatrani u ranim fazama projektnog planiranja, trenutna produkciona implementacija fokusirana je na Whisper backend zbog dokumentovane višezjezične pokrivenosti, jednostavnosti *fine-tuninga* putem Hugging Face ekosistema i mogućnosti direktnog poređenja sa javno dostupnim baseline vrednostima. Model-agnostički dizajn arhitekture opisane u poglavlju III predviđa buduću integraciju alternativnih backendova.

Problem *garbage supervision*, nesklada između audio segmenta i pridruženog referentnog teksta, posebno je izražen pri automatskom rezanju dugih snimaka bez preciznog vremenskog poravnanja. Radovi iz oblasti automatske izgradnje govornih korpusa [4] identifikuju ovo kao jedan od ključnih faktora koji ograničava kvalitet automatski prikupljenih trening skupova. Pristupi zasnovani na vremenskim oznakama na nivou reči i naknadnoj proveru kvaliteta direktno adresiraju ovaj problem. Striktna kontrola *holdout* skupa na nivou izvornih fajlova, a ne samo segmenata, primenjena je kao metodološka odluka autora radi garantovanja striktnog integriteta evaluacije.

Za evaluaciju ASR sistema standardno se koriste dve metrike: stopa grešaka na nivou reči (WER) i stopa grešaka na nivou karaktera (CER). WER se formalno definiše kao:

$$WER = \frac{S + D + I}{N}$$

gde S označava broj supstitucija (pogrešno prepoznatih reči), D broj brisanja (ispuštenih reči), I broj umetanja (ekstra reči u hipotezi), a N ukupan broj reči u referentnom tekstu. WER može biti veći od 1,0 ukoliko model generiše znatno više reči nego što ih sadrži referenca.

CER je definisan analogno, ali na nivou pojedinačnih karaktera:

$$CER = \frac{Sc + Dc + Ic}{Nc}$$

gde su Sc, Dc, Ic i Nc analogni brojevi supstitucija, brisanja, umetanja i referentnih karaktera, redom. U kontekstu morfološki bogatih jezika kao što je srpski, CER je često informativan dodatak WER-u jer manje kašnjava morfološke varijante koje ne menjaju značajno sadržaj poruke. Na primer, greška na nivou jednog dijakritičkog znaka (č → c) rezultuje jednom supstitucijom na nivou karaktera ali kompletnom supstitucijom na nivou reči.

AWR (eng. *Aligned Word Ratio*) je interni indikator kvaliteta poravnanja koji se koristi u *alignment-first* pipeline-u i definiše se kao:

$$AWR = \frac{|W_{poravnate}|}{|W_{referenca}|}$$

gde $|W_{poravnate}|$ označava broj uspešno poravnatih reči između ASR hipoteze i referentnog teksta, a $|W_{referenca}|$ ukupan broj reči u referenci. AWR blizak vrednosti 1,0 ukazuje da vremenski okvir segmenta tačno odgovara pridruženom referentnom tekstu, dok niske vrednosti AWR signaliziraju potencijalni *garbage supervision* problem.

III. METOD

Metodologija rada zasnovana je na modularnom *pipeline*-u koji automatizuje put od sirovih medijskih arhiva do finalnog ASR modela. Ključni fokus je na *alignment-first* pristupu, koji osigurava visok kvalitet nadzornog signala kroz precizno vremensko poravnanje

segmenata. U nastavku su detaljno opisane faze akvizicije, obrade i same arhitekture sistema.

A. Akvizicija podataka

Za prikupljanje podataka razvijena je namenski prilagođena komponenta za automatsko preuzimanje audio-tekst parova sa RTS portal. Komponenta pretražuje portal po zadatim ključnim rečima i za svaki pronađeni članak verifikuje istovremenu dostupnost audio snimka i validnog tekstualnog transkripata pre preuzimanja. Filter odbacuje sadržaj stariji od 1. januara 2024. godine radi obezbeđivanja aktuelnosti i konzistentnosti govornog stila u skupu podataka.

Ulazna validacija audio-tekst parova obuhvata više kriterijuma: proveru formata audio datoteke (MP3, WAV, FLAC), postojanje referentnog teksta, realističnost statističkih indikatora kao što su trajanje snimka i dužina teksta, te konzistentnost imenovanja parova. Parovi koji ne zadovoljavaju ove kriterijume beleže se u evidenciji problematičnih parova radi naknadnog pregleda i ne ulaze u dalji pipeline.

B. Alignment-First priprema segmenata

Centralni kvalitativni korak pipeline-a je komponenta za izgradnju poravnatih segmenata. Osnovna premisa je da naivno rezanje dugih snimaka na segmente fiksne dužine, bez uzimanja u obzir granica reči, neizbežno uvodi greške u nadzorni signal: početak ili kraj segmenta može presecati reč, a referentni tekst pridružen segmentu može sadržati reči koje akustički nisu prisutne u datom segmentu. *Alignment-first* pristup rešava ovaj problem kroz sledeće korake:

- Ekstrakcija vremenskih oznaka: primenom *faster-Whisper* modela [7] nad sirovim audio snimkom ekstrahuju se vremenske oznake na nivou svake reči u ASR hipotezi.
- Poravnanje hipoteze i reference: primenom *SequenceMatcher* algoritma vrši se mapiranje tokena ASR hipoteze na odgovarajuće tokene referentnog teksta. Ovaj korak identifikuje podudaranja, brisanja i umetanja na nivou reči između dva niza.
- Segmentacija: dugi snimci seku se na segmente ciljane dužine, pri čemu su granice segmenata postavljene isključivo na granicama reči prepoznatih u hipotezi.
- Izračunavanje indikatora kvaliteta: za svaki segment izračunavaju se: udeo nepravnatih reči (*unmatched ratio*), udeo uspešno poravnatih reči (AWR), gustina karaktera po sekundi (CPS, eng. *Characters Per Second*) i trajanje segmenta.

Segmenti se klasifikuju u tri kategorije na osnovu AWR vrednosti. Na osnovu testova i analize kvaliteta poravnanja, definisani su pragovi $AWR_{min} = 0,6$ i $AWR_{rec} = 0,75$. Formalni pragovi prikazani su u Tabeli I.

TABELA I KLASIFIKACIJA SEGMENTATA PREMA AWR PRAGU

Kategorija	AWR uslov	Postupanje
Regularni	$AWR \geq AWR_{rec}$	Uključeni u trening
Teški (nekritični)	$AWR_{min} \leq AWR < AWR_{rec}$	Uključeni (opcionarno)
Toksični	$AWR < AWR_{min}$	Odbačeni

Toksični segment (eng. *toxic sample*) je segment čija je vrednost AWR ispod minimalno prihvatljivog praga, što ukazuje da referentni tekst u velikoj meri ne odgovara audio sadržaju segmenta. Uključivanje takvih segmenata u trening unosi direktan šum u nadzorni signal i degradira kvalitet fine-tuninga. Na osnovu primenjenih kriterijuma, za svaki skup podataka kreira se lista prihvaćenih segmenata spremna za dalju obradu, uz prateći izveštaj sa zbirnim statistikama kvaliteta čitavog korpusa.

C. Podela podataka i zaštita od curenja

Projekat implementira dvostepenu disciplinu podele podataka koja garantuje integritet evaluacije. U prvom koraku, pre izgradnje poravnatih segmenata, skup sirovih audio-tekst parova deli se na trening/validacioni podskup i striktni *holdout* podskup. Važno je napomenuti da se podela vrši na nivou sirovih parova, a ne na nivou segmenata. Ovo sprečava situaciju u kojoj bi različiti segmenti istog audio snimka mogli da se nađu u različitim skupovima. Pipeline za poravnanje zatim se izvršava odvojeno za trening i *holdout* skup, čime se garantuje da *holdout* primeri ne ulaze u trening ni kroz indirektno efekte algoritma poravnanja.

U drugom koraku, sprovodi se automatizovana provera preklapanja izvornih datoteka kako bi se verifikovalo potpuno odsustvo zajedničkih audio izvora između trening manifesta i *holdout* liste. Za finalnu evaluaciju modela na platformi Kaggle, sprovedena validacija potvrdila je da ne postoji preklapanje podataka (broj zajedničkih uzoraka iznosi nula), čime je pružen formalni dokaz o odsustvu curenja informacija (*data leakage*). Pored ove provere, projekat uključuje i poseban test integriteta podele koji se može pokrenuti kao deo CI/CD procesa.

D. Arhitektura sistema i trening konfiguracija

Arhitektura projekta zasnovana je na *model registry* obrascu koji odvaja apstraktni interfejs od konkretnih implementacija. Apstraktni adapter definiše ugovor koji svaki ASR backend mora da ispoštuje, uključujući metode za inicijalizaciju, transkripciju i pripremu za trening. *ModelRegistry* klasa upravlja registrovanim backendovima i vrši fabrički izbor na osnovu parametra `--model_type` pri pokretanju CLI ulaza. *Model registry* dizajn omogućava dodavanje novih modela bez prepisivanja trening ili evaluacionih skripti.

Kao polazna tačka za *fine-tuning* korišćen je javno dostupan *openai/whisper-base* model. Trening je implementiran primenom Hugging Face *Seq2SeqTrainer* okvira [8]. Konfiguracija podržava više naprednih opcija: *fp16* preciznost za efikasno korišćenje GPU

memorije, *gradient_accumulation_steps* za simulaciju većeg efektivnog batch-a, *gradient_checkpointing* za smanjenje potrošnje memorije, parcijalno odmrzavanje enkoder slojeva (*--unfreeze_encoder*) i LoRA (eng. *Low-Rank Adaptation*) adapterski trening (*--use_lora*). Selekcija najboljeg modela vrši se prema minimalnoj WER vrednosti na validacionom skupu.

Reproduktivnost je obezbeđena kroz: postavljanje fiksnog semena (eng. *seed*) pre svakog koraka koji koristi slučajnost, čuvanje kompletne *run* konfiguracije u YAML formatu, evidentiranje git hash-a, pip freeze liste i split manifesta uz svaki *run*, te mogućnost nastavka treninga iz tačke (eng. *checkpoint*) putem opcije *--resume_from_checkpoint*. Trening je izvršavan na Kaggle platformi radi dostupnosti GPU resursa.

E. Evaluaciona procedura i tekstualna normalizacija

Evaluacija je sprovedena isključivo na striktnom *holdout* skupu koji nije bio dostupan tokom treninga ni u jednoj fazi razvoja sistema. Za računanje WER-a i CER-a primenjuje se konzistentna tekstualna normalizacija primenom *SerbianTextPreprocessor* komponente. Normalizacija obuhvata: konverziju u mala slova, uklanjanje interpunkcije koja ne nosi semantički sadržaj, normalizaciju razmaka, konverziju cifara u tekstualnu formu gde je primenljivo i usklađivanje pisma (latinizacija). Ista normalizacija dosledno se primenjuje i na hipotezu i na referencu, čime se WER i CER čine nezavisnim od površnih varijacija zapisa.

Baseline i *fine-tuned* model porede se uz identične parametre dekodiranja, na istom skupu uzoraka identifikovanih stabilnim *sample_id* vrednostima. Pre svake evaluacije pokreće se provera integriteta predikcija koja verifikuje kompletnost skupa predikcija i ispravnost mapiranja *sample_id* vrednosti. Za poređenje se koriste striktno uparivanje po *sample_id*, čime se eliminiše mogućnost pogrešnih uparivanja uzoraka.

IV. REZULTATI I DISKUSIJA

Ovo poglavlje prikazuje rezultate eksperimenta organizovane u sedam tematskih celina. Poglavlje A opisuje obim i kvalitet skupa podataka nakon primene pipeline-a. Poglavlje B daje lingvističku analizu korpusa. Poglavlje C prikazuje kvantitativnu evaluaciju WER i CER metrika. Poglavlja D i E analiziraju performanse kroz akustičku i taksonomsku prizmu, redom. Poglavlje F kvantifikuje proširenje vokabulara modela putem OOV analize, a poglavlje G osvetljava inženjerske doprinose projekta u oblasti reproduktivnosti.

A. Obim i kvalitet skupa podataka

Tabela II prikazuje obim podataka po skupovima nakon primene *alignment-first* pipeline-a na Kaggle platformi. Značajna razlika u obimu u odnosu na inicijalni lokalni prototip rezultat je većeg ulaznog skupa podataka i dostupnosti Kaggle GPU resursa za izvršavanje skupe faze poravnanja.

TABELA II PREGLED SKUPA PODATAKA NAKON ALIGNMENT-FIRST PIPELINE-A

Skup	Ul. parovi	Segmenti	Odbač. (QA)
Trening/Val	544 (537 val.)	4.888	455 (9,3%)
Holdout	232 (231 val.)	2.194	140 (6,4%)

Stopa odbacivanja segmenata usled QA filtriranja iznosi 9,3% za trening i 6,4% za *holdout* skup. Ova razlika je konzistentna sa očekivanjem da *holdout* parovi, prikupljeni iz različitog skupa članaka, mogu imati blago višu prosečnu kvalitetu poravnanja. Analiza distribucije kvaliteta segmenata na ukupnom skupu od 9.276 uzoraka identifikuje tri kategorije: regularne segmente (56,64%), teške nekritične segmente sa AWR između minimalnog praga i preporučene vrednosti (40,45%) i toksične segmente sa AWR ispod minimalnog praga (2,91%). Toksični segmenti se u potpunosti odbacuju i ne ulaze u trening.

B. Lingvistička analiza skupa

Lingvistička analiza skupa podataka otkriva karakteristike konzistentne sa očekivanjima za RTS informativni portal. Latinično pismo dominira sa prosečnim udelom od 99,76% karaktera (*lat_ratio* = 0,998), dok je udeo ćirilice marginalan (*cyr_ratio* = 0,002). Ova skoro isključiva latinizacija posledica je uređivačke prakse RTS digitalnog portala i ima direktan uticaj na ponašanje ASR sistema. Model uči iz gotovo isključivo latiničnih referenci, što može ograničiti performanse u scenariju mešovitog pisma.

Udeo cifara u tekstu iznosi prosečno 1,05% (*std* = 1,78%), što je konzistentno sa informativnim stilom u kome se brojevi retko zapisuju kao cifre u govoru. Udeo specijalnih znakova (interpunkcija, zagrade, crtice) iznosi prosečno 2,71% (*std* = 1,06%). Analiza n-grama otkriva visok udeo funkcionalnih reči karakterističnih za srpski informativni diskurs (predlozi, članova), što je relevantno za interpretaciju WER vrednosti: greške na funkcionalnim rečima manje utiču na razumljivost nego greške na sadržinskim rečima.

C. Kvantitativna evaluacija

Tabela III prikazuje WER i CER vrednosti za baseline i *fine-tuned* model na striktnom *holdout* skupu sa 2.172 uparena uzorka. Verifikacija odsustva curenja (*overlap_count* = 0) garantuje da prikazane vrednosti reflektuju stvarne performanse sistema na neviđenim podacima.

TABELA III REZULTATI EVALUACIJE NA HOLDOUT SKUPU (n = 2.172)

Model	WER	CER	ΔWER
Baseline (whisper-base)	0,4944	0,1908	—
Fine-tuned (whisper-base)	0,4877	0,1920	-0,0067 (-1,36%)

Fine-tuned model ostvaruje apsolutno smanjenje WER-a od 0,0067, što odgovara relativnom poboljšanju od 1,36%. Wilcoxon test rangirane oznake za parni uzorak potvrđuje statističku značajnost poboljšanja (*W* =

1.064.669,5; $p = 0,000012$; $p_{\text{Bonferroni}} = 0,000059$). Oba modela imaju normalno raspoređene WER vrednosti po Shapiro-Wilk testu ($p > 0,05$), što potvrđuje validnost primene parametarskih testova kao komplementarne analize.

Veličina efekta izražena Cohen-ovim koeficijentom d_{th} iznosi 0,085, što prema konvencionalnoj interpretaciji Cohena (1988) [9] spada u kategoriju malog efekta ($d < 0,2$ = mali, $d < 0,5$ = srednji, $d \geq 0,8$ = veliki). Mala veličina efekta ($d = 0,085$) je važna za pravilno tumačenje rezultata: statistička značajnost ($p = 0,000012$) odražava pre svega veličinu uzorka ($n = 2.172$), dok mala veličina efekta ukazuje da je praktični doprinos *fine-tuninga* skroman. Takav rezultat je karakterističan za *low-resource fine-tuning* scenarije i ne umanjuje vrednost metodoloških doprinosa rada. Naprotiv, postavlja realističan kvantitativni okvir koji je preduslov za interpretabilno dalje istraživanje.

Blagi regres CER metrike ($\Delta CER = +0,0012$) inicijalno je neintuitivno jer je suprotan smeru WER poboljšanja. Moguće objašnjenje je karakteristični *trade-off* pri *fine-tuningu* sa ograničenim podacima: model koji je prilagođen na RTS domenskom vokabularu bolje segmentuje reči (manji WER), ali taj dobitak dolazi uz blagu degradaciju preciznosti na nivou karaktera za neke primere. Alternativno objašnjenje je da *fine-tuned* model u određenim slučajevima preferira morfološki kompleksnije oblike reči koji su tačni na nivou lekseme, ali sadrže duže sekvence karaktera potencijalno nepoklopljene sa referencom. Pearson-ov koeficijent korelacije između AWR poravnosti segmenta i WER *fine-tuned* modela iznosi $r = -0,527$ ($p < 10^{-15}$, Spearman $\rho = -0,519$), što potvrđuje da segmenti višeg poravnanja sistematski postižu niži WER. Navedena korelacija direktno empirijski validira *alignment-first* pristup.

D. Akustička analiza i breakdown po SNR klasama

Akustička analiza sprovedena je na 2.194 segmenta *holdout* skupa. Segmenti su podeljeni u dve klase prema procenjenom odnosu signal-šum (SNR, eng. *Signal-to-Noise Ratio*) koristeći prag izračunat iz distribucije intenziteta ($SNR_{\text{prag}} = 46,28$ dB). Tabela IV prikazuje prosečne WER vrednosti po SNR klasi za oba modela.

TABELA IV WER PO SNR KLASI SEGMENTA NA HOLDOUT SKUPU

SNR klasa	n	WER baseline	WER fine-tuned	ΔWER
High SNR (studio)	1.086	0,4701	0,4648	-0,0053
Low SNR / Field	1.086	0,5252	0,5162	-0,0090

Fine-tuning ostvaruje veće apsolutno poboljšanje na segmentima sa niskim SNR-om ($\Delta WER = -0,009$) nego na segmentima studijskog kvaliteta ($\Delta WER = -0,005$). Ovaj nalaz je konzistentan sa očekivanjem da baseline model ima veći prostor za poboljšanje tamo gde je akustički uslov zahtevniji.

Finija analiza po četiri akustička režima, kombinacije visokog/niskog odnosa nultih prelaza (ZCR, eng. *Zero*

Crossing Rate) i SNR-a, prikazana u Tabeli V dodatno razjašnjava ove razlike.

TABELA V ANALIZA PO AKUSTIČKIM REŽIMIMA (ZCR $\times$ SNR) NA HOLDOUT SKUPU

Opis	n	Frikativne greške
High ZCR + Low SNR	113	0,3811
Low ZCR + Low SNR	973	0,3911
High ZCR + High SNR	973	0,3276
Low ZCR + High SNR	113	0,3303

Tabela V pokazuje da režim sa visokim ZCR-om i niskim SNR-om ($n = 113$) ima povišenu stopu grešaka na frikativnim glasovima (0,381) u odnosu na režime sa visokim SNR-om ($\sim 0,33$). Mann-Whitney test potvrđuje statističku značajnost ove razlike između High-ZCR/Low-SNR grupe i ostalih akustičkih režima, što formalizuje empirijski nalaz.

High-ZCR/Low-SNR režim identifikuje konkretnu akustičku klasu koja je posebno izazovna za sistem, kombinacija visoke brzine nultih prelaza (ZCR) i niskog odnosa signal-šum (SNR) degradira percepciju frikativnih glasova poput /š/, /č/, /ž/, /ć/. Ovi glasovi su već inherentno podložni greškama zbog dijakritičke konfuzije, te njihova akustička degradacija u šumovitom okruženju dodatno pojačava stopu grešaka. Ovaj zajednički uzrok, fonetska srodnost frikativa i vizuelna srodnost odgovarajućih dijakritičkih znakova, objašnjava kumulativni efekat.

E. Analiza grešaka i taksonomija

Taksonomija grešaka prikazana u Tabeli TABELA VI TAKSONOMIJA GREŠAKA NA HOLDOUT SKUPU identifikuje dominantnu kategoriju lingvističkih grešaka (87,25% svih grešaka) u poređenju sa akustičkim greškama (10,50%) i strukturnim greškama poravnanja (2,26%). Akustičke greške imaju značajno viši srednji WER (0,607) od lingvističkih (0,470), što ukazuje da ova manjinska kategorija sadrži najteže uzorke za sistem.

TABELA VI TAKSONOMIJA GREŠAKA NA HOLDOUT SKUPU

Kategorija greške	Udeo (%)	Srednji WER
Lingvističke (morfolologija/ortografija)	87,25	0,470
Akustičke (buka/prekid govora)	10,50	0,607
Strukturne (tajming/poravnanje)	2,26	0,589

Analiza konfuzija na nivou karaktera, koja je prikazana u Tabeli VII, identifikuje konfuziju dijakritičkih znakova kao najčešći izvor lingvističkih grešaka. Parovi č/c i ž/z pojavljuju se simetrično u oba smera konfuzije, što ukazuje da model nije razvio konzistentno razlikovanje fonetski bliskih parnjaka. Oba karaktera percipira kao akustički ekvivalentne u većem broju konteksta. Opisana konfuzija je poznat izazov za ASR sisteme trenirane nad višejezičnim skupovima bez eksplicitnog fonetskog modeliranja specifičnosti pojedinog jezika.

TABELA VII TOP-5 KONFUZIJA NA NIVOU KARAKTERA

Konfuzija	Broj pojav.
č → c	1.696
c → č	1.560
ž → z	1.383
z → ž	1.361
đ → dj	134

F. OOV analiza – proširenje vokabulara

OOV analiza kvantifikuje sposobnost fine-tuned modela da prepozna domenski relevantne srpske lekseme koje su bile sistematski odsutne iz izlaza baseline modela. Tabela VIII prikazuje top OOV tokene podeljene u dve grupe prema stepenu korekcije.

TABELA VIII OOV ANALIZA: IZOSTANCI PO TOKENU (n = 2.172 uzorka)

Token	Baseline izost.	Fine-tuned izost.	Dobitak
u	190	0	+190
srbiije	129	0	+129
nije	97	0	+97
rekao	97	0	+97
predsednik	90	0	+90
a	271	233	+38
na	242	158	+84
sa	213	149	+64
iz	225	170	+55
za	158	95	+63

Nalazi OOV analize dokumentuju dva jasno različita obrasca korekcije. Prva grupa, tokeni *u*, *srbiije*, *nije*, *rekao* i *predsednik* pokazuje kompletnu OOV korekciju (finetuned izostanak = 0), što ukazuje da su to reči čija distribucija u RTS domenu bila dovoljna da *fine-tuning* u potpunosti nauči njihov akustički model. Ove reči su domenski specifične i tipične za srpski informativni diskurs (npr. *predsednik*), ali i kratke funkcionalne reči koje baseline model tretira kao previše ambivalentne.

Druga grupa, pretežno jednoslovna i dvoslovna funkcionalna reč (*na*, *sa*, *iz*, *za*) – pokazuje parcijalno poboljšanje sa rezidualnim izostancima. Ovi tokeni su fonetski kratki i akustički ambivalentni u govoru sa šumom, što objašnjava zašto *fine-tuning* nije u potpunosti eliminisao propuste. Ukupno, OOV analiza potvrđuje da *fine-tuning* uspešno proširuje efektivni vokabular modela ka domenski relevantnim srpskim leksemama i sistematski koriguje propuste baseline modela u prepoznavanju funkcionalnih reči srpskog jezika.

Prosečna normalizovana Levenshtein distanca na nivou karaktera (norm_char_lev) iznosi 0,1875 (std =

0,088), a njena distribucija ima pozitivan *skew* sa dugim repom prema visokim vrednostima (max = 0,711). Ovo ukazuje da manjinski skup uzoraka sa veoma visokim CER-om (tj. akustički teškim ili neporavnatim segmentima) značajno doprinosi ukupnoj prosečnoj vrednosti metrike.

G. Reproductivnost i inženjerske prakse

Pored performansi modela, posebno vredi istaknuti inženjerski doprinos projekta u oblasti reproductivnosti. Svaki *run* čuva: kompletnu YAML konfiguraciju, git *hash* verzije koda, *pip freeze* listu zavisnosti, *split* manifeste sa *sample_id* vrednostima za svaki podskup i sve evaluacione artefakte (metrike, predikcije, logovi). Navedeni skup artefakata čini svaki *run* u potpunosti reproductivnim bez potrebe za ručnim evidentiranjem parametara.

Kanonski *packaging* pristup garantuje identičnost koda koji se izvršava lokalno i na Kaggle platformi, eliminisanjem mogućnosti drifta između razvojnog i produkcionog okruženja. Sveobuhvatna EDA implementirana u modularnom format pokriva akvizicijski inventar, kvalitativnu analizu, lingvističku analizu, akustičku analizu, evaluacionu statistiku i taksonomiju grešaka, čime je celokupan analitički tok dokumentovan i reproductivan.

V. ZAKLJUČAK

U ovom radu prezentovan je end-to-end ASR pipeline za srpski jezik u informativnom medijskom domenu sa fokusom na *alignment-first* pripremu podataka i striktnu evaluacionu metodologiju. Sistem je izrađen i evaluiran na skupu audio-tekst parova prikupljenih sa RTS portala, uz kompletnu automatizaciju od akvizicije podataka do izvoza evaluacionih artefakata.

Ključni doprinos rada nije samo ostvareno poboljšanje WER metrike, već pre svega uspostavljena metodološka disciplina: automatizovana verifikacija odsustva curenja podataka, *alignment-first* pristup koji eliminiše greške nadzornog signala pre trening faze, konzistentna tekstualna normalizacija koja obezbeđuje uporedivost metrika i reproductivno pokretanje celokupnog pipeline-a sa čuvanjem svih artefakata. Ove praktične inženjerske odluke jednako su vredan doprinos kao i konačne metrike jer stvaraju temelje za pouzdan dalji razvoj sistema.

Fine-tuning *openai/whisper-base* modela na 4.888 poravnatih segmenata rezultuje statistički značajnim smanjenjem WER-a sa 0,4944 na 0,4877 (Wilcoxon p = 0,000012, Cohen-ov d_{th} = 0,085). Mala veličina efekta ukazuje na skroman praktični doprinos, ali je to očekivano za *low-resource fine-tuning* scenarije sa ograničenom količinom podataka. Sistem ostvaruje veće apsolutne dobitke na akustički zahtevnijim segmentima (Low SNR: ΔWER = -0,009) što potvrđuje vrednost domenskog prilagođavanja. Analiza grešaka identifikuje konfuziju srpskih dijakritičkih parnjaka (č/c, ž/z) kao dominantni izvor lingvističkih grešaka (87,25% ukupno), a OOV analiza dokumentuje značajno proširenje aktivnog vokabulara modela ka domenski relevantnim

leksemama, sa kompletnom korekcijom za sedam domenski specifičnih tokena.

Ograničenja rada uključuju: umeren apsolutni dobitak WER-a koji sugerise da su ograničena količina trening podataka i veličina modela ograničavajući faktori, blagi CER regres kao *trade-off* domenskog *fine-tuninga*, i domensku specifičnost evaluacije, generalizacija na konverzacijski ili dijalekatski srpski zahteva posebnu proveru. Produkcijska evaluacija je Whisper-centrična, te model-agnostički dizajn arhitekture još nije bio eksperimentalno verifikovan na alternativnim backendovima.

Predloženi pravci budućeg rada obuhvataju:

- Eksperimentisanje sa većim Whisper varijantama (*whisper-small*, *whisper-medium*) na istom skupu podataka radi procene doprinosa kapaciteta modela.
- Integraciju augmentacije zvuka (dodavanje šuma, promene tempa i tonaliteta) radi povećanja robusnosti na akustički šum.
- Ciljanu augmentaciju primera sa konfuzijama dijakritičkih znakova kao direktnog odgovora na nalaze analize grešaka.
- Proširenje skupa podataka na druge srpske medijske domene radi testiranja interdomenskog transfera.
- Eksperimentalnu validaciju model-agnostičke arhitekture kroz integraciju i evaluaciju Wav2Vec 2.0 ili HuBERT backendova.

LITERATURA

- [1] R. Ardila, M. Branson, K. Davis, M. Henretty, M. Kohler, J. Meyer, R. Morais, L. Saunders, F. M. Tyers i G. Weber, "Common Voice: A Massively-Multilingual Speech Corpus", u Proc. LREC, Marseille, 2020, str. 4218–4222.
- [2] V. Delić, M. Sečujski, N. Jakovljević, M. Janev, R. Obradović, i D. Pekar, "Speech Technologies for Serbian and Kindred South Slavic Languages", u *Advances in Speech Recognition*, InTech, 2010.
- [3] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey i I. Sutskever, "Robust Speech Recognition via Large-Scale Weak Supervision", u Proc. ICML, 2023.
- [4] V. Panayotov, G. Chen, D. Povey i S. Khudanpur, "Librispeech: An ASR corpus based on public domain audio books", u Proc. ICASSP, Brisbane, 2015, str. 5206–5210.
- [5] A. Baevski, H. Zhou, A. Mohamed i M. Auli, "wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations", u *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [6] W.-N. Hsu, B. Bolte, Y.-H. H. Tsai, K. Lakhota, R. Salakhutdinov i A. Mohamed, "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units", *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 29, str. 3451–3460, 2021.
- [7] SYSTRAN, "faster-whisper: Faster Whisper transcription with CTranslate2," *GitHub repository*, 2023. [Online]. Available: <https://github.com/SYSTRAN/faster-whisper>. [Accessed: 01-Apr-2026].
- [8] T. Wolf, L. Debut, V. Sanh, J. Chaumond et al., "Transformers: State-of-the-Art Natural Language Processing", u Proc. EMNLP (Demonstracije), 2020, str. 38–45.
- [9] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2nd ed. Hillsdale, NJ: Lawrence Erlbaum Associates, 1988.