

Sistem za automatsko prepoznavanje srpskog govora

Miloš Milanović R2 5/2025, Bojan Živanić R2 22/2025

1. Definicija problema

Potrebno je razviti sistem za automatsko prepoznavanje govora koji će primati audio fajl na srpskom jeziku i generisati odgovarajuću tekstualnu transkripciju. Glavni cilj je prilagođavanje (fine-tuning) postojećih pretreniranih modela za prepoznavanje govora na srpski jezik, posebno na domen vesti i informativnih emisija sa Radio Televizije Srbije (dnevnik, reportaže, podkasti).

2. Motivacija problema rešavanog u projektu

Automatska transkripcija audio sadržaja sa vesti i informativnih emisija ima važne praktične primene, posebno za osobe sa oštećenim sluhom. Sistem bi mogao automatski generisati titlove za TV dnevnik, informativne emisije i podkaste, čineći ovaj sadržaj pristupačnijim širokoj publici. Ovo je od posebnog značaja jer trenutno većina TV programa u Srbiji nema kvalitetne titlove u realnom vremenu.

3. Relevantna literatura

3.1. Robust Speech Recognition via Large-Scale Weak Supervision [\[pdf\]](#)

Tema rada: Rad predstavlja Whisper, model za automatsko prepoznavanje govora treniran na 680,000 sati multilingvalnog i multitask audio materijala prikupljenog sa interneta. Model je dizajniran kao encoder-decoder Transformer arhitektura koja može vršiti transkripciju, identifikaciju jezika, i prevođenje govora.

Podaci: Skup podataka obuhvata 680,000 sati audio zapisa na 117 različitih jezika, prikupljenih sa interneta (YouTube video titlovi, podkasti, javno dostupni audio materijal). Dataset je raznovrstan po domenima - razgovori, konferencije, podkasti, audio knjige.

Metodologija: Whisper koristi encoder-decoder Transformer arhitekturu. Audio signal se konvertuje u log-mel spektrogram sa 80 filterskih kanala, encoder procesira audio features i kreira latentne reprezentacije, dok decoder autoregresivno generiše tekst. Trening se vrši korišćenjem cross-entropy loss funkcije.

Evaluacija: Model je evaluiran na više poznatim benchmark dataset-ovima kao što su LibriSpeech, Common Voice i Fleurs, korišćenjem Word Error Rate (WER) metrike koja meri procenat grešaka u transkripciji. Whisper-base model postiže WER od oko 10-15% na clean audio za engleski jezik.

Rezultati: Whisper modeli pokazuju dobru robusnost na šum i različite akustičke uslove zahvaljujući raznolikosti podataka tokom treniranja. Model se može koristiti bez dodatnog treniranja (zero-shot transfer), ali fine-tuning na specifičnom domenu i jeziku značajno poboljšava performanse.

Zaključak: U našem projektu ćemo koristiti Whisper kao jedan od glavnih kandidata za ASR sistem. Planiramo da primenimo fine-tuning pristup da prilagodimo pretreniran model na specifičnosti srpskog jezika i domena vesti i informativnih emisija. Očekujemo da će multilingvalna priroda Whisper modela omogućiti brže učenje na srpskom jeziku.

3.2. A Framework for Self-Supervised Learning of Speech Representations [\[pdf\]](#)

Tema rada: Rad predstavlja Wav2Vec2, model koji koristi self-supervised learning za učenje reprezentacija govora iz neoznačenih audio podataka. Model se prvo pretrenira na velikim količinama unlabeled audio materijala, a zatim se fine-tunuje na manjim količinama labeled

podataka za ASR zadatke.

Podaci: Za pretraining je korišćen LibriSpeech dataset sa 960 sati čitanog govora na engleskom jeziku. Fine-tuning je vršen na značajno manjim labeled podsetovima - eksperimenti su rađeni sa 100 sati, 10 sati, pa čak i 1 sat labeled podataka.

Metodologija: Wav2Vec2 koristi contrastive learning pristup - audio se enkoduje u latentne reprezentacije, deo reprezentacija se maskira, i model uči da razlikuje prave maskirane vrednosti od distraktora. Nakon pretreninga, dodaje se CTC (Connectionist Temporal Classification) head za fine-tuning na transkripciju govora.

Evaluacija: Model je evaluiran na LibriSpeech test skupovima korišćenjem WER metrike. Sa potpunim labeled dataset-om (960 sati), Wav2Vec2 postiže WER od 1.8% na test-clean skupu. Čak i sa samo 10 minuta labeled podataka, model postiže upotrebljive rezultate.

Rezultati: Ključni rezultat rada je da Wav2Vec2 može postići odlične ASR performanse čak i sa vrlo malom količinom labeled podataka. To je posebno važno za low-resource jezike gde je labeled audio tešk i skup za prikupljanje. Model pokazuje da se sa dovoljno unlabeled audio materijala može naučiti efikasna reprezentacija govora.

Zaključak: Wav2Vec2 će biti razmatran kao alternativa Whisper modelu u našem projektu. Njegova sposobnost da radi sa malom količinom labeled podataka je ključna prednost za srpski jezik. U projektu ćemo isprobati fine-tuning Wav2Vec2 modela na našem skupu audio snimaka vesti sa RTS-a i uporediti ga sa Whisper pristupom.

3.3 HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units [\[pdf\]](#)

Tema rada: HuBERT (Hidden-Unit BERT) je model za self-supervised learning audio reprezentacija koji koristi masked prediction pristup inspirisan BERT modelom iz oblasti obrade prirodnog jezika. Model uči da predviđa maskirane delove audio signala bez potrebe za labelovanim podacima tokom pretreniranja.

Podaci: Za pretraining je korišćen LibriSpeech dataset sa 960 sati neoznačenog audio materijala. Kao i kod Wav2Vec2, fine-tuning se vrši na manjim labeled podsetovima LibriSpeech dataseta.

Metodologija: HuBERT prvo konvertuje audio u continuous features, zatim primenjuje maskiranje (slično BERT-u), i trenira Transformer encoder da predviđa discrete klaster labele za maskirane regione. Model se iterativno poboljšava kroz više faza - u svakoj fazi se vrši novo klasterovanje naučenih reprezentacija, i model se ponovo trenira sa novim klaster labelama.

Evaluacija: HuBERT je evaluiran na LibriSpeech i drugim ASR benchmark dataset-ovima korišćenjem WER metrike. Model postiže rezultate konkurentne sa Wav2Vec2 modelom, a na nekim zadacima i bolje performanse.

Rezultati: HuBERT pokazuje da jednostavniji masked prediction pristup može biti jednako efikasan kao složeniji contrastive learning iz Wav2Vec2. Model pokazuje dobre performanse u low-resource scenarijima i može se efikasno fine-tunovati na nove jezike i domene sa ograničenom količinom podataka.

Zaključak: HuBERT će biti treća opcija koju ćemo razmotriti u projektu. Planiramo da uporedimo sva tri modela (Whisper, Wav2Vec2, HuBERT) tokom realizacije projekta kako bih utvrdili koji najbolje funkcioniše na srpskom jeziku i domenu vesti i informativnih emisija. Cilj je empirijski evaluirati koji pristup daje najbolje rezultate na našem specifičnom skupu podataka.

4. Skup podataka

Za ovaj projekat ćemo koristiti skup podataka prikupljen automatskim preuzimanjem sa javno dostupnih izvora - audio snimci vesti i informativnih emisija sa RTS portala (Radio Televizija Srbije). Skup se trenutno sastoji od 370 parova audio fajlova u MP3 formatu sa pridruženim tekstualnim transkripcijama u .txt formatu.

Planirano je da se skup proširi sa dodatnim preuzimanjem do ovima od 500 do 600 parova (audio, transkripcija) tokom realizacije projekta. Audio fajlovi su različite dužine trajanja, od nekoliko sekundi do nekoliko minuta. Tekstualne transkripcije su na srpskom jeziku (mešovina ćirilice i latinice) i sadrže izgovoreni sadržaj audio snimka. Svi tekstovi su standardizovani konverzijom u latinično pismo. Domen obuhvata vesti i informativne emisije sa RTS-a iz različitih kategorija - politika, ekonomija, kultura, društvo i sport. U prvoj fazi model će se trenirati isključivo na govornom sadržaju, bez korišćenja informacije o kategoriji. Plan je da se podaci prikupe što raznolikije, ali bez striktnog balansiranja između domena.

5. Metodologija

U projektu ćemo koristiti transfer learning pristup - uzimamo pretreniran model koji je naučio opšte reprezentacije govora na velikom skupu podataka, i fine-tunujemo ga na našem manjem skupu podataka na srpskom jeziku. Razmatraćemo tri modela: OpenAI Whisper (base ili small verzija) koji je multilingvalni encoder-decoder model i već podržava više od 100 jezika, Wav2Vec2 koji je self-supervised model i može se fine-tunovati dodavanjem CTC head-a, i HuBERT koji je sličan Wav2Vec2 i koristi tehniku maskiranja (masked prediction) tokom predtreniranja.

Plan preprocesiranja obuhvata normalizaciju tekstualnih transkripcija koja će se sastojati od transliteracije u latinicu, koverzije brojeva u reči, uklanjanja interpunkcije i normalizacije razmaka. Audio podaci učitavaće se sa standardnom frekvencijom od 16kHz, a tokom treniranja primenićemo tehnike proširenja skupa podataka (Data Augmentation) kao što su perturbacija i dodavanje šuma, kako bi se poboljšala robusnost modela.

Za Whisper razmatramo zamrzavanje encoder dela modela (koji je naučio opšte akustičke features) i treniranje samo decoder dela koji uči specifičnosti srpskog jezika i ortografije, što smanjuje broj parametara koje treba trenirati i ubrzava proces. Za Wav2Vec2 i HuBERT dodaćemo CTC head na vrh pretrenirane feature encoder mreže i fine-tunovaćemo model na labeled audio podacima.

Koristićemo HuggingFace Transformers biblioteku koja ima gotove implementacije svih pomenutih modela i podržava jednostavan fine-tuning kroz Trainer API. Za procesiranje audio podataka koristićemo Librosa biblioteku, a za data loading koristićemo HuggingFace Datasets biblioteku.

6. Metod evaluacije

Podatke ćemo podeliti na trening, validacioni i test skup u razmeri 80/10/10. Tokom treninga ćemo pratiti validation loss nakon svake epohe kako bismo pratili da li model napreduje i da bismo sprečili overfitting (rano zaustavljanje). Nakon završenog treninga, izvršićemo finalnu evaluaciju na test skupu koji model nije video tokom treninga. Koristićemo Word Error Rate (WER) kao primarnu metriku evaluacije. WER se računa kao (Broj supstitucija + Broj brisanja + Broj umetanja) / Ukupan broj reči u referenci. Dodatno ćemo posmatrati i Character Error Rate (CER) kao sekundarnu metriku, koja računa greške na nivou karaktera umesto reči.